PÓS TECH

DEVOPS E ARQUITETURA CLOUD

FASE 4 | AULA 04 -

COLETANDO MÉTRICAS DE INFRAESTRUTURA A APLICAÇÕES EM CONTÊINERES

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura e Aplicações em Contêineres

SUMÁRIO

O QUE VEM POR AÍ? 3
HANDS ON 4
SAIBA MAIS 5
MERCADO, CASES E TENDÊNCIAS 13
O QUE VOCÊ VIU NESTA AULA? 14
REFERÊNCIAS 15

FIAP

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura a Aplicações em Contêineres

O QUE VEM POR AÍ?

A análise abrangente sobre as camadas de métricas e o papel da observabilidade em sistemas modernos, abordando desde a infraestrutura física até as métricas de negócio, descreve como cada camada — infraestrutura, sistema operacional, máquinas virtuais, orquestração e aplicação — contribui com dados específicos que, quando correlacionados, permitem compreender o comportamento completo do ecossistema. A coleta de métricas é, em seus aspectos técnicos, o uso de agentes e exporters, os modelos de coleta pull e push e o impacto da granularidade na detecção de eventos e nos custos operacionais. A padronização por meio de frameworks como OpenMetrics e OpenTelemetry é essencial para garantir consistência, interoperabilidade e correlação entre métricas de diferentes níveis.

Além dos fundamentos técnicos, discutiremos as boas práticas e desafios de operação, enfatizando a importância de unir métricas de infraestrutura e aplicação para obter visibilidade real sobre a experiência do usuário. O pipeline unificado de métricas é descrito como o eixo central da observabilidade, envolvendo instrumentação, coleta, armazenamento, visualização e governança. Serão apresentados exemplos de KPIs técnicos e de negócio, destacando como o alinhamento entre eles permite ações proativas e decisões orientadas a resultados. Por fim, a documentação ressaltará a necessidade de equilibrar granularidade, custo e segurança, defendendo uma adoção incremental e iterativa da observabilidade — começando com uma pilha mínima e evoluindo conforme a maturidade técnica e operacional da organização cresce.

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura e Aplicações em Contêineres

HANDS ON

Implantaremos um ambiente de observabilidade utilizando Prometheus, Grafana e cAdvisor dentro de um cluster Kubernetes. O primeiro passo será instalar o Prometheus, que será responsável pela coleta das métricas dos componentes do ambiente. Em seguida, configuraremos o cAdvisor, que coleta dados de uso de CPU, memória e rede dos containers, e integraremos ao Prometheus para que as métricas sejam capturadas automaticamente. Por fim, o Grafana será instalado e configurado como ferramenta de visualização, permitindo criar dashboards que mostram em tempo real o comportamento da infraestrutura e dos serviços monitorados.

Na segunda etapa, implementaremos uma aplicação simples que expõe métricas próprias, simulando uma camada de aplicação que gera indicadores de negócio, como número de requisições ou tempo de resposta. Essa aplicação também será monitorada pelo Prometheus e visualizada no Grafana, permitindo observar a relação entre métricas técnicas e métricas de negócio. Ao final, o ambiente criado demonstrará, na prática, como construir um pipeline unificado de métricas, aplicando os conceitos de observabilidade, padronização e correlação entre camadas descritos na documentação.

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura a Aplicações em Contêineres

SAIBA MAIS

Vamos descrever as camadas de métricas que compõem um ecossistema observável moderno, os fundamentos técnicos da coleta, os padrões e protocolos para unificação e padronização de sinais e as boas práticas para transformar dados em decisões de negócio. O objetivo é guiar equipes de operações e desenvolvimento na montagem e evolução de um pipeline de métricas capaz de abranger desde o hardware cru até métricas de negócio customizadas, mantendo equilíbrio entre granularidade, custo e utilidade.

Visão Geral das Camadas de Métricas

A primeira camada a ser compreendida é a camada de infraestrutura física e virtual. Em ambientes bare metal e máquinas virtuais, os indicadores de CPU, memória, utilização de disco e taxa de transferência de rede são sinais primários que mostram saturação ou degradação de performance. Esses sinais, quando observados isoladamente, fornecem uma fotografia do estado do recurso, mas raramente explicam causas de alto nível. A camada do sistema operacional complementa a visão de infraestrutura com métricas relacionadas a processos em execução, consumo de recursos por processo, e logs do sistema que registram eventos críticos como falhas de drivers, erros de kernel ou problemas de I/O. Essas informações são essenciais para diagnosticar problemas que não aparecem em métricas agregadas, por exemplo, quando um processo específico consome memória de maneira gradual até acionar um OOM killer.

Acima do sistema operacional estão as máquinas virtuais e os hosts geridos por provedores de nuvem. Aqui aparecem métricas específicas de provedores, como as disponibilizadas pelo AWS CloudWatch, Google Cloud Monitoring (antigo Stackdriver) e Azure Monitor. Essas métricas frequentemente incluem metadados proprietários sobre autoescalamento, utilização de instâncias reservadas, limites de quota e latência de serviços gerenciados. Em arquiteturas de escala elástica, sinalizar corretamente eventos de escala automática e investigar métricas de provisão e desprovisionamento é crucial para entender flutuações de performance e custo.

A camada de orquestração introduz métricas e eventos que representam a saúde do plano de controle e do plano de dados. Em plataformas como Kubernetes,

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura a Aplicações em Contêineres

são métricas relevantes o status dos nós, a saúde dos pods e containers, eventos emitidos pelo scheduler e métricas do kubelet e do control plane. O comportamento do scheduler, decisões de re-scheduling e eventos de OOM em containers aparecem aqui e ajudam a traçar conexões entre a infraestrutura subjacente e as cargas de trabalho.

Na camada de contêineres, as métricas devem cobrir uso de CPU e memória por contêiner, quantidade de reinicializações (restart count), latência de rede entre containers e métricas de I/O de disco por volume ou por container. Em ambientes multi-tenant ou com densidade alta de containers, a observação por container torna-se vital para isolar problemas entre serviços e para detectar ruídos introduzidos por co-locação.

A camada de aplicação contém métricas de negócio e métricas customizadas que refletem diretamente a experiência do usuário e os objetivos do negócio. Métricas como latência de requisição, taxa de erro por endpoint, throughput por método, contadores de eventos de negócio (por exemplo, número de transações aprovadas) e histogramas de tempo de processamento devem ser instrumentadas pela aplicação para tornar possível correlacionar degradações técnicas com impacto no negócio.

Fundamentos de Coleta de Métricas

A coleta de métricas exige escolhas arquiteturais com implicações fortes em custos operacionais e latência de detecção. Agentes e exporters são o método mais comum para extrair dados de recursos e serviços. Node Exporter oferece métricas de OS/infrastructure em ambientes Linux, cAdvisor expõe estatísticas de containers como uso de CPU e memória e bibliotecas de clientes do Prometheus estão presentes para instrumentar aplicações. Agentes como Telegraf e Collectd podem ser usados para coletar métricas e empurrá-las para backends variados.

Uma decisão central é a do modelo Pull versus Push. O modelo Pull, adotado por Prometheus, permite que o coletor central busque métricas em endpoints instrumentados, simplificando a descoberta e a autorização em ambientes dinâmicos. O modelo Push, usado por sistemas como Graphite ou por pushgateway do Prometheus em casos especiais, permite que fontes com conectividade limitada ou curtos períodos de vida entreguem métricas de forma proativa. Cada modelo tem

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura e Aplicações em Contêineres

trade-offs: Pull facilita descoberta e scraping centralizado, Push é útil para jobs curtos ou batchs, mas requer mecanismos de agregação e deduplicação.

Granularidade e frequência de coleta têm impacto direto em capacidade de armazenamento e na capacidade de detectar eventos curtos. Coletar métricas de alta cardinalidade com alta frequência gera grandes volumes de dados. A decisão sobre janela de retenção e downsampling deve levar em conta os SLI/SLO definidos e o tipo de análise que será realizada. Eventos de curta duração podem ser perdidos se a janela de scrape for muito longa, enquanto scrapes muito frequentes aumentam custos e carga de rede.

Padronização e Observabilidade

Padronizar modo de expor métricas facilita correlação e análise cross-stack. OpenMetrics e OpenTelemetry representam esforços para criar formatos abertos e compatíveis para métricas, traces e logs. OpenMetrics define convenções para exposição de métricas que simplificam scraping e parsing. OpenTelemetry amplia o escopo com instrumentação unificada para métricas, traces e logs, oferecendo SDKs e exportadores para uma variedade de destinos.

Em ambientes dinâmicos, o uso de labels ou tags é imprescindível. Identificadores como container_id, namespace, service_name, cluster e region devem seguir convenções estabelecidas para que consultas e agregações sejam estáveis. Nomes inconsistentes ou tags faltantes impedem correlação entre métricas. Labels bem pensadas habilitam agregações por serviço, por versão de release, por equipe e por ambiente, tornando possível responder perguntas como “qual versão está gerando mais latência” ou “quais namespaces apresentam maior crescimento de errors”.

Correlações entre métricas de infra e métricas de aplicação são a peça-chave da observabilidade efetiva. Exemplo prático: ao observar aumento de latência em um endpoint, verificar simultaneamente a utilização de CPU em pods que atendem aquele serviço, latência de chamadas a base de dados e filas de mensagens ajuda a identificar se a causa é saturação de CPU, contenção de I/O ou latência externa. Ferramentas que suportam consultas multidimensionais e correlação temporal reduzem tempo de diagnóstico.

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura e Aplicações em Contêineres

Ferramentas Típicas e Integrações

No nível de infraestrutura e sistema operacional, Node Exporter e Telegraf representam agentes maduros que expõem métricas padrão do host. Para containers, cAdvisor é uma ferramenta de referência para obter métricas em nível de runtime container. Em clusters Kubernetes, kubelet metrics e kube-state-metrics expõem informações do estado do cluster e recursos planejados que não aparecem em métricas de runtime, como desejado versus o atual para deployments e estados de readiness.

Para instrumentação de aplicações, bibliotecas Prometheus e SDKs OpenTelemetry são amplamente adotados. Em ecossistemas Java, Spring Actuator e Micrometer fornecem integração pronta para expor métricas compatíveis com Prometheus, incluindo timers, counters e gauges. Além disso, agentes APM, como Elastic APM, Datadog APM e ferramentas SaaS, fornecem rastreamento distribuído e métricas de aplicação com painéis e alertas gerenciados.

Na camada de visualização e análise, Prometheus é frequentemente usado como motor de séries temporais para métricas, enquanto Grafana é o padrão de facto para dashboards. Soluções comerciais como Datadog e Elastic APM oferecem integração entre logs, métricas e traces, com capacidades avançadas de correlação e visualização, porém com custo financeiro associado.

Boas Práticas Operacionais

Monitorar apenas infraestrutura é uma armadilha comum. Para entender o impacto real no usuário, é imprescindível coletar métricas de aplicação juntamente com métricas de infraestrutura. Integrar essas visões evita diagnósticos errôneos, por exemplo, quando um problema atribuído a um container resulta na verdade de uma falha de rede subjacente ou de um disco saturado no host.

Unificar camadas em um único pipeline de observabilidade facilita rastreamentos causais. Em ambientes containerizados, um problema pode manifestar-se em uma das camadas, portanto, centralizar coletores, padronizar labels e garantir que todas as camadas enviem metadados permite buscas eficientes e correlações automáticas.

Automatizar descoberta é essencial em ambientes dinâmicos. Em Kubernetes, serviços sobem e descem constantemente; portanto, mecanismos como service

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura e Aplicações em Contêineres

discovery nativo do Prometheus ou integração com APIs do cluster garantem que novas instâncias sejam automaticamente monitoradas sem intervenção manual. A automação também traz desafios: é preciso garantir que labels geradas dinamicamente permaneçam estáveis o suficiente para consultas históricas, por isso, usar combinações de identificadores (por exemplo: service_name + pod_template_hash) pode ser mais confiável que container_id puro.

Definir KPIs e SLIs é uma prática que deve orientar todas as escolhas de coleta e retenção. KPIs técnicos, como p95 de latência, taxa de erros e taxa de throughput, devem ser traduzidos em SLIs que reflitam o nível aceitável de serviço. SLIs alimentam SLOs e os SLOs orientam alertas e prioridades de resposta operacional.

Pipeline Unificado de Métricas: arquitetura e implementação

Um pipeline unificado começa no ponto de instrumentação. No nível de aplicação, instrumentação granular expõe métricas via endpoint HTTP no formato OpenMetrics ou via SDKs OpenTelemetry. No nível de infra, agentes como Node Exporter e cAdvisor rodam como daemons nos nós. Esses coletores expõem métricas que são periodicamente escrapeadas por um serviço central de coleta. Em Kubernetes, Prometheus opera dentro do cluster e descobre targets por meio de ServiceMonitor e endpoints de annotations, permitindo scrapes autoconfiguráveis.

Após coleta, métricas podem ser encaminhadas para diferentes destinos. Um armazenamento de séries temporais como Thanos ou Cortex permite retenção de longo prazo e escalabilidade, além de suporte a downsampling. Exportadores e pipelines de transformação podem enriquecer métricas com labels adicionais, agregar dados de alta cardinalidade e aplicar políticas de retenção por métrica. Para análise em tempo real, um produto de streaming de métricas pode alimentar dashboards e alertas. Logs e traces complementam as métricas e devem ser correlacionáveis por ids de request ou por labels comuns para obter contexto completo.

A seguir, um exemplo simplificado de configuração Prometheus para descoberta automática em Kubernetes. O snippet serve como referência de como configurar scraping para serviços instrumentados no namespace de produção.

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura e Aplicações em Contêineres

```
     YAML – Prometheus

     scrape_configs:
       - job_name: 'kubernetes-services'
         kubernetes_sd_configs:
           - role: service
         relabel_configs:
           -                                          source_labels:
[__meta_kubernetes_service_annotation_prometheus_io_scrape]
             action: keep
             regex: true
           -                                          source_labels:
[__meta_kubernetes_service_annotation_prometheus_io_path]
             target_label: __metrics_path__
             regex: (.+)
           - source_labels: [__meta_kubernetes_namespace]
             target_label: namespace
           - source_labels: [__meta_kubernetes_service_name]
             target_label: service_name
```

Código Fonte 1: configuração Prometheus - YAML – Prometheus
Fonte: Elaborado pelo autor (2026)

A arquitetura de pipeline também deve considerar o armazenamento e o custo. Soluções on-premises oferecem controle total, enquanto soluções SaaS simplificam operação. Uma abordagem híbrida, em que métricas de alta fidelidade e curta duração ficam em armazenamento local e métricas agregadas são enviadas para retenção de longo prazo em um backend dimensionável, é prática comum.

Exemplos de KPIs Técnicos vs. KPIs de Negócio

KPIs técnicos servem para garantir a saúde do sistema. Exemplos representativos são latência p95 de requisições, taxa de erros 5xx por segundo e utilização média de CPU por pod em horário de pico. KPIs de negócio medem impacto no usuário e no resultado financeiro: número de transações aprovadas por minuto, taxa de conversão por campanha e receita por segmento. A chave é mapear KPIs técnicos que influenciem diretamente KPIs de negócio e priorizar os que têm maior impacto no funil.

Um caso de uso prático: se a latência p95 de um endpoint crítico aumenta, isso pode reduzir a taxa de conversão. Definir um SLO de conversão por janela horária e mapear alertas para thresholds técnicos que, historicamente, precedem a queda na conversão, permite ações proativas. Esse tipo de mapeamento exige análise histórica e experimentação controlada.

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura e Aplicações em Contêineres

Trade-offs: Granularidade, Custo e Armazenamento

Escolher granularidade envolve ponderar o custo de armazenamento e a utilidade da informação. Métricas com alta cardinalidade, tais como latências por usuário, podem gerar volumes insustentáveis. Em contrapartida, reduzir cardinalidade por meio de agregações pode esconder problemas específicos. Estratégias comuns incluem amostragem, agregação por janela de tempo e retenção diferenciada: salvar dados de alta resolução por curto período e versões agregadas por mais tempo.

O custo explícito de um pipeline inclui custo de rede para scrapes, custo de CPU/memória dos coletores e custo de armazenamento do TSDB. Custos indiretos incluem o tempo das equipes para manutenção de regras de scraping e dashboards. Projetar limiares e políticas de retenção alinhadas com SLIs minimiza custos sem sacrificar a capacidade de investigação quando necessário.

Considerações de Segurança e Governança

Expor endpoints de métricas exige cautela. Endpoints não autorizados podem revelar topologia interna, versões de software e métricas sensíveis que auxiliam em técnicas de ataque. Autenticação e autorização, uso de redes privadas e rotação de credenciais são medidas necessárias. Além disso, a anonimização de dados pessoais antes de enviar métricas para soluções externas é um requisito legal em diversas jurisdições.

Políticas de governança para métricas devem incluir regras para rotulagem, retenção e quem pode criar ou alterar métricas e dashboards. Um catálogo de métricas corporativo, ajuda a evitar duplicidade e a garantir consistência semântica entre equipes.

Encerramento: Caminho para Implementação

A adoção de um pipeline observável começa por identificar os KPIs de negócio e definir SLIs claros. Em seguida, instrumentam-se a aplicação e a infraestrutura de forma incremental, priorizando endpoints e serviços críticos. Implantar uma pilha mínima viável, por exemplo, Prometheus para coleta central, Grafana para visualização e um agente padrão nos nós, permite obter valor rápido enquanto se evolui para retenção e governance mais sofisticadas.

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura e Aplicações em Contêineres

A jornada deve ser iterativa: medir, analisar, ajustar. Implementar testes de carga e simular degradations ajuda a validar que os SLIs respondem adequadamente. Documentar convenções de labels, criar playbooks de resposta a alertas e automatizar descoberta e instrumentação reduzem atrito operacional.

Referências e Leituras Recomendadas

Para aprofundamento técnico, recomenda-se consultar as especificações de OpenMetrics e OpenTelemetry, bem como documentação oficial das ferramentas citadas como Prometheus, Grafana, Node Exporter, cAdvisor, kube-state-metrics e agentes de provedores de nuvem. Estudar casos de uso de Thanos/Cortex para retenção longa e escalabilidade também é altamente recomendado.

FIAP

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura e Aplicações em Contêineres

MERCADO, CASES E TENDÊNCIAS

Understanding OpenTelemetry Architecture and Components - Link.

Elastic Observability Documentation - Link.

AWS CloudWatch Documentation - Link.

Google Cloud Monitoring (Stackdriver) – Link.

Azure Monitor Documentation - Link.

FIAP

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura a Aplicações em Contêineres

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, apresentamos uma visão sobre as camadas de métricas que compõem um ecossistema observável moderno, explicando como a coleta e correlação de dados desde a infraestrutura até a aplicação permitem entender o comportamento de sistemas complexos. Foram abordadas as métricas de hardware, sistema operacional, máquinas virtuais, orquestração e containers, além das métricas de negócio que refletem diretamente a experiência do usuário. O conteúdo também detalhou os fundamentos técnicos da coleta, destacando o uso de agentes, exporters e modelos de coleta pull e push, bem como a importância de definir granularidade e frequência adequadas para equilibrar custo e precisão na observação.

Além disso, enfatizamos a necessidade da padronização e governança no processo de observabilidade, por meio de ferramentas e padrões como OpenMetrics e OpenTelemetry, que permitem integração entre métricas, logs e traces. Destacamos as boas práticas operacionais, como a unificação de camadas em um pipeline centralizado, o uso de automação em ambientes dinâmicos e a definição de KPIs e SLIs que alinhem métricas técnicas e de negócio.

Por fim, discutimos temas como segurança, custo, retenção e escalabilidade, finalizando com um guia para implementação prática e gradual de um pipeline observável, priorizando valor rápido e evolução contínua conforme a maturidade da organização aumenta.

FIAP

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura e Aplicações em Contêineres

REFERÊNCIAS

BEYER, JONES, PETOFF & MURPHY. **Engenharia de Confiabilidade do Google.** São Paulo: Novatec, 2022.

Charity Majors, Liz Fong-Jones, George Miranda. **Observability Engineering: Achieving Production Excellence**, EUA, O'Reilly Media, 2023;

Brian Brazil. **Prometheus: Up & Running**, EUA, O'Reilly Media, 2018.

OPENOBSERVABILITY. **OpenTelemetry Specification.** Disponível em: https://opentelemetry.io/docs. Acesso em: 22 jan. 2026.

FIAP

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com

Coletando Métricas de Infraestrutura e Aplicações em Contêineres

PALAVRAS-CHAVE

Monitoramento. Observabildade. Métricas. Análise.Sistemas.

FIAP

PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com



PDF exclusivo para Gabriel Pinelli Silva - rm373763
gabrieltocaccelli@gmail.com